Séquence 5 - Activité 1: le codage des caractères

En recherchant un extrait du « Seigneur des anneaux » sur Internet avec un navigateur mal configuré, nous sommes tombés sur une page web, dont le contenu est reproduit ci-dessous.

> Les anneaux de pouvoir (au nombre de 20) sont d'abord dÃ©crits au dÃ©but de la CommunautÃ© de l'Anneau dans un poÃ¨me, connu depuis longtemps des Elfes, Ã©noncÃ© par Gandalf Ã Frodon Sacquet.
>
> Trois anneaux pour les rois Elfes sous le ciel,
>
> Sept pour les seigneurs Nains dans leurs demeures de pierre,
>
> Neuf pour les Hommes, mortels destinÃ©s au trÃ©pas,
>
> Un pour le Seigneur TÃ©nÃ©breux sur son sombre trÃ´ne,
>
> Dans le Pays de Mordor oÃ¹ s'Ã©tendent les Ombres.
>
> Un anneau pour les gouverner tous. Un anneau pour les trouver,
>
> Un anneau pour les amener tous et dans les tÃ©nÃ¨bres les lier,
>
> Au Pays de Mordor oÃ¹ s'Ã©tendent les Ombres.

Analyser

Expliquer la situation. Préciser quel type de lettres pose problème.

Le code ASCII

Le code ASCII (**A**merican **S**tandard **C**ode for **I**nformation **I**nterchange), défini aux Etats-Unis en 1963, est basé sur un tableau contenant les caractères les plus utilisés en langue anglaise. Chaque caractère est représenté par un nombre écrit sur 7 bits (ce qui donne $2^7 = 128$ combinaisons possibles).

Table de codes ascii (en hexadécimal)

Hex	Symbol	Hex	Symbol	Hex	Symbol	Hex	Symbol	Hex	Symbol	Hex	Symbol
20	(space)	30	0	40	@	50	P	60	`	70	p
21	!	31	1	41	A	51	Q	61	a	71	q
22	"	32	2	42	B	52	R	62	b	72	r
23	#	33	3	43	C	53	S	63	c	73	s
24	$	34	4	44	D	54	T	64	d	74	t
25	%	35	5	45	E	55	U	65	e	75	u
26	&	36	6	46	F	56	V	66	f	76	v
27	'	37	7	47	G	57	W	67	g	77	w
28	(	38	8	48	H	58	X	68	h	78	x
29	)	39	9	49	I	59	Y	69	i	79	y
2A	*	3A	:	4A	J	5A	Z	6A	j	7A	z
2B	+	3B	;	4B	K	5B	[	6B	k	7B	{
2C	,	3C	<	4C	L	5C	\	6C	l	7C	|
2D	-	3D	=	4D	M	5D	]	6D	m	7D	}
2E	.	3E	>	4E	N	5E	^	6E	n	7E	~
2F	/	3F	?	4F	O	5F	_	6F	o	7F	

Analyser et réutiliser des solutions

- Coder, à l'aide de la table ci-dessus, la phrase suivante : *La compagnie de l'anneau*.
- Retrouver le texte correspondant au code ASCII suivant : (46 72 6F 64 6F 6E 20 6C 65 20 48 6F 62 62 69 74).
- Justifier, pourquoi il n'est pas possible de coder correctement le texte *Mon précieux* à l'aide du code ASCII.

La norme ISO 8859-1 (latin 1)

La nécessité de représenter des caractères non présents dans la table ASCII tels que ceux de l'alphabet latin comme le «à», le «é», «ç» ... impose l'utilisation d'un autre code. Ces codes sont des extensions du code ASCII. Pour cela le 8ème bit est utilisé ce qui permet de coder 256 caractères (128 caractères supplémentaire par rapport au code ASCII de base). On parle de code ASCII étendu.

Les tables ascii étendu sont souvent présentés sous la forme de tableau à double entrées.

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0x	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	HT	LF	VT	FF	CR	SO	SI
1x	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2x	SP	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3x	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4x	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5x	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6x	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7x	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	DEL
8x	PAD	HOP	BPH	NBH	IND	NEL	SSA	ESA	HTS	HTJ	VTS	PLD	PLU	RI	SS2	SS3
9x	DCS	PU1	PU2	STS	CCH	MW	SPA	EPA	SOS	SGCI	SCI	CSI	ST	OSC	PM	APC
Ax	NBSP	¡	¢	£	¤	¥	¦	§	¨	©	ª	«	¬		®	¯
Bx	°	±	²	³	´	µ	¶	·	¸	¹	º	»	¼	½	¾	¿
Cx	À	Á	Â	Ã	Ä	Å	Æ	Ç	È	É	Ê	Ë	Ì	Í	Î	Ï
Dx	Ð	Ñ	Ò	Ó	Ô	Õ	Ö	×	Ø	Ù	Ú	Û	Ü	Ý	Þ	ß
Ex	à	á	â	ã	ä	å	æ	ç	è	é	ê	ë	ì	í	î	ï
Fx	ð	ñ	ò	ó	ô	õ	ö	÷	ø	ù	ú	û	ü	ý	þ	ÿ

L'ISO, organisation internationale de normalisation, propose plusieurs variantes de ce code, adaptée aux différentes langues. Nous utilisons la norme ISO-8859-1 nommée aussi ISO-Latin1.

Réutiliser des solutions

Coder le texte *Mon précieux* en utilisant la table « ASCII étendu » précédente.

La norme ISO 10646 (Unicode)

Présentation

La généralisation de l'utilisation d'Internet dans le monde a ainsi nécessité une prise en compte d'un nombre beaucoup plus important de caractères. Ce que permet la norme Unicode qui établit une correspondance unique caractère - code numérique (on dit aussi *charset* en anglais).

Le répertoire Unicode peut contenir plus d'un million de caractères. Unicode définit des méthodes standardisées pour coder et stocker cet index sous forme de séquence d'octets : UTF-8, UTF-16, UTF-32 et leurs différentes variantes.

L'UTF-8 est l'encodage (*encoding* en anglais) le plus répandu. Les navigateurs Internet utilisent le codage UTF-8 par défaut. Le langage de programmation utilisé en NSI (Python) gère l'Unicode par défaut.

L'index des caractères UNICODE est disponible à l'adresse suivante http://www.unicode.org/fr/charts/charindex.html. Par ailleurs, une description détaillée de l'UTF-8 peut être trouvée sur Wikipedia https://fr.wikipedia.org/wiki/UTF-8

Description rapide et simplifiée

L'encodage UTF-8 utilise 1, 2, 3 ou 4 octets. Si le code du caractère est inférieur ou égal à 127, on n'utilise qu'un octet avec le bit de poids fort à 0. Sinon, les bits de poids fort du premier octet forment une suite de 1 indiquant le nombre d'octets utilisés pour coder le caractère. Les octets suivants commencent tous par le bloc binaire 10.

Représentation binaire UTF-8	Signification
0xxx xxxx	1 octet utilisé
110x xxxx 10xx xxxx	2 octets utilisés
1110 xxxx 10xx xxxx 10xx xxxx	3 octets utilisés
1111 0xxx 10xx xxxx 10xx xxxx 10xx xxxx	4 octets utilisés

Analyser et mobiliser des concepts

Sous Unicode le caractère *inférieur ou égal* a comme point de code U+2A7D.

- Quelle la valeur binaire de 0x2A7D ? Combien d'octets seront nécessaires pour représenter ce caractère en unicode UTF-8?
- Déterminer la représentation binaire puis hexadécimale du caractère inférieur ou égal en Unicode UTF-8.