TABLES DE DONNEES

Les tableaux (suite et fin)

Qu'est-ce qu'un tableau de tableaux?

Les éléments d'un tableau peuvent être des entiers, des flottants, des chaines de caractères, mais aussi ... des tableaux! Ainsi, l'écriture suivante est parfaitement valide:

```
t = [[1, 2, 3, 4], [5, 6, 7, 8]]
```

`t` est un tableau composé de **deux** tableaux de **quatre** entiers. Pour faciliter la compréhension, on aussi saisir `t` de la manière suivante:

```
t = [[1, 2, 3, 4],
     [5, 6, 7, 8]]
```

Cette présentation met bien en évidence une structure à **deux** lignes et **quatre** colonnes. Un tel tableau, dont les lignes ont la même taille, est appelé une **matrice**.

Les tableaux de tableaux sont utilisés, entre autres, pour les manipulations des données tabulées (voir ci-dessous) ou des images.

Comment accéder aux éléments d'un tableau de tableaux?

On peut envisager un *accès indexé*. Ce qui revient à dire que l'accès à un élément du tableau `t[i][j]` se fera grâce à deux index i et j qui représentent respectivement le numéro de la ligne et le numéro de la colonne.
Exemples

```
t = [[1, 2, 3, 4],
     [5, 6, 7, 8]]
#Elément de la 2ème ligne, 3ème colonne --> i=1, j=2
print(t[1][2])

7
```

On peut aussi envisager de modifier la valeur située à la ligne i et à la colonne j.

```
#Modification de la valeur de la 1ere ligne, 4eme colonne --> i=0, j=3
t[0][3] = 10
print(t)

[[1, 2, 3, 10], [5, 6, 7, 8]]
```

À faire

Exercice d'application directe
Soit la matrice:

```
t = [[15, 17, 22],
     [17, 25, 27],
     [31, 33, 35]]
```

- Que vaut `t[1][2]` ?
- Que doit-on modifier pour avoir `[[15, 17, 22], [17, 25, 45], [31, 33, 35]]` ?

Comment construire un tableau de tableaux en compréhension?

Pour construire un tableau `t` ayant n lignes et p colonnes initialisé avec des zéros par exemple, on peut procéder comme suit:

```
n = 3
p = 4

t = [[0]*p for i in range(n)]
```

Notation

L'instruction `[0]*p` est équivalente à `[0] + [0] + ... + [0]` c'est à dire `p` tableaux `[0]`) soit `[0, 0, ..., 0]` composé de `p` zéros.

À faire

Application directe
Que vaut `t` après l'instruction `t = [[i, i+1] for i in range(2)]` ?

Organisation des données sous forme de tables

Repères historiques

Le compilateur fortran de l'**IBM OS/360** supportait dès 1972 des données tabulées, au format *csv (comma-separated values)*. Source

Qu'est-ce qu'une table de données?

Une table de données est un **arrangement de lignes et de colonnes**. Les lignes ont divers synonymes: *enregistrement, p-uplet, vecteur, etc.*. Il en est de même pour les colonnes: *champ, propriété, attribut, etc.* L'organisation des données sous forme de table (on dit aussi *sous forme tabulée*) est très répandue.

Exemple: un jeu de données en lien avec des artistes évoluant dans le milieu du rap durant ces 30 dernières années. Les données sont disponibles à cette adresse et on peut les récupérer sous forme de fichier `csv`. Le fichier comporte 581 *enregistrements* qui ont 12 *champs*. En voici un aperçu:

	Name	Categories	URL	Years Active Start
0	Trae Tha Truth	rapper	https://en.wikipedia.org/wiki/Trae_tha_Truth	1998
1	13 Block	group	https://genius.com/artists/13-block	2014

	Name	Categories	URL	Years Active Start
2	Jay Rock	rapper	https://en.wikipedia.org/wiki/Jay_Rock	2003
3	Droogz Brigade	group	https://genius.com/artists/Droogz-brigade	2008

	Name	Categories	URL	Years Active Start
4	Jeff le Nerf	rapper	https://fr.wikipedia.org/wiki/Jeff_Le_Nerf	1997

...	Years Active End	Deathdate	Clip Example YouTube	City
0			https://www.youtube.com/embed/QqKh5Bhx3YE	Houston
1			https://www.youtube.com/embed/ewExz3cx_RM	Sevran
2			https://www.youtube.com/embed/fk10RoZV4fw	Watts
3			https://www.youtube.com/embed/e9UbNKuxzzk	Toulouse
4			https://www.youtube.com/embed/kSiLpodQTBQ	Grenoble

Remarque

il n'est pas rare dans des jeux de données réels, d'avoir des champs vides. Il faudra, peut être en tenir compte lors des traitements.

Les données tabulées sont très importantes en informatique: on les utilise dans de nombreux domaines (web, IA, calcul scientifique, etc.).

Quelle structure de données pour représenter une table ?

Les données sont habituellement séparées des programmes qui les traitent, dans un fichier texte.
On utilise souvent des fichiers au format **csv** (*comma separated values*). Chaque ligne de ce fichier correspond à un enregistrement (*p-uplet*). Les différents champs (*attributs*) étant séparés par un délimiteur (*virgule, point-virgule, tabulation, etc.*).

La librairie standard de python possède un module adapté à la lecture (*et à l'écriture*) de ce type de fichiers: le **module csv**.

Importation sous forme de tableau de tableaux

On souhaite importer le fichier précédent regroupant des artistes: `rapworld.csv` situé dans le dossier `data`, sous la forme d'un tableau de tableaux. Une bonne pratique pour ouvrir le fichier et y réaliser des opérations consiste à utiliser la structure suivante:

À connaître

```
import csv


with open('data/rapworld.csv', newline='', encoding='utf8') as f:
    table = [ligne for ligne in csv.reader(f, delimiter=';')]
```

Utilisons cette façon de procéder pour afficher les 3 premières lignes de cette table:

```python
import csv


with open('data/rapworld.csv', newline='', encoding='utf8') as f:
    table = [ligne for ligne in csv.reader(f, delimiter=';')]

for i in range(3):
    print(i,'-', table[i])
    print() # insère une ligne vide pour plus de lisibilité
```

```
0 - ['Name', 'Categories', 'URL', 'Years Active Start', 'Birthdate', 'Summary', 'Years
Active End', 'Deathdate', 'Clip Example YouTube', 'City', 'Neighborhood', 'Coordinates']

1 - ['Trae Tha Truth', 'rapper', 'https://en.wikipedia.org/wiki/Trae_tha_Truth', '1998',
'1980-07-03', 'Frazier Othel Thompson III (born July 3, 1980), better known by his stage
name Trae tha Truth or simply Trae, is an American hip hop recording artist from Houston,
Texas.', '', '', 'https://www.youtube.com/embed/QqKh5Bhx3YE', 'Houston', '',
'29.674552,-95.363456']

2 - ['13 Block', 'group', 'https://genius.com/artists/13-block', '2014', '', '13 Block is a
french Hip Hop group from Sevran,  Seine-Saint-Denis. The group is composed of DeTess,
OldPee, Zefor, et Zed.', '', '', 'https://www.youtube.com/embed/ewExz3cx_RM', 'Sevran', '',
'48.929103,2.533054']
```

Bilan

Cette première solution est simple à mettre en oeuvre, cependant elle souffre de deux défauts:

- on doit mémoriser l'ordre des attributs;
- la première ligne apparait comme une ligne de données, il va falloir l'ignorer lors des traitements.

À faire

Application directe

À l'index 533 de la table précédente, on trouve un groupe réunionnais. De quelle ville ce groupe est-il originaire?

Importation sous forme de tableau de n-uplets nommés

Pour éviter les inconvénients précédents, on peut importer les données tabulées sous forme de tableau de p-uplets nommés. Un code python typique est le suivant:

À connaître

```python
import csv


with open('data/rapworld.csv', newline='', encoding='utf8') as f:
    table = [dict(ligne) for ligne in csv.DictReader(f, delimiter=';')]
```

Les premiers éléments affichés confirment que l'on a bien un tableau de dictionnaire:

```python
import csv


with open('data/rapworld.csv', newline='', encoding='utf8') as f:
    table = [dict(ligne) for ligne in csv.DictReader(f, delimiter=';')]

for i in range(3):
    print(table[i])
    print()
```

```
{'Name': 'Trae Tha Truth', 'Categories': 'rapper', 'URL':
'https://en.wikipedia.org/wiki/Trae_tha_Truth', 'Years Active Start': '1998', 'Birthdate':
'1980-07-03', 'Summary': 'Frazier Othel Thompson III (born July 3, 1980), better known by
his stage name Trae tha Truth or simply Trae, is an American hip hop recording artist from
Houston, Texas.', 'Years Active End': '', 'Deathdate': '', 'Clip Example YouTube':
'https://www.youtube.com/embed/QqKh5Bhx3YE', 'City': 'Houston', 'Neighborhood': '',
'Coordinates': '29.674552,-95.363456'}

{'Name': '13 Block', 'Categories': 'group', 'URL': 'https://genius.com/artists/13-block',
'Years Active Start': '2014', 'Birthdate': '', 'Summary': '13 Block is a french Hip Hop
group from Sevran,  Seine-Saint-Denis. The group is composed of DeTess, OldPee, Zefor, et
Zed.', 'Years Active End': '', 'Deathdate': '', 'Clip Example YouTube':
'https://www.youtube.com/embed/ewExz3cx_RM', 'City': 'Sevran', 'Neighborhood': '',
'Coordinates': '48.929103,2.533054'}

{'Name': 'Jay Rock', 'Categories': 'rapper', 'URL':
'https://en.wikipedia.org/wiki/Jay_Rock', 'Years Active Start': '2003', 'Birthdate': '1985-
03-31', 'Summary': 'Johnny Reed McKinzie, Jr., (born March 31, 1985), better known by his
stage name Jay Rock, is an American hip hop recording artist from Watts, California.',
'Years Active End': '', 'Deathdate': '', 'Clip Example YouTube':
'https://www.youtube.com/embed/fk10RoZV4fw', 'City': 'Watts', 'Neighborhood': 'Nickerson
Gardens projects', 'Coordinates': '33.930751,-118.24893'}
```

On remarque que ce tableau ne contient plus la première ligne. Cette dernière a servi à fournir les clés du dictionnaire créé.

Note

L'instruction `dict` du tableau construit en compréhension est nécessaire avec les dernières versions de python, afin d'avoir des éléments de type dictionnaire.

À faire

Application directe
Les informations concernant `Future Crew` se trouvent maintenant à l'index 532 de cette table (rappel: la 1ere ligne a servi pour créer les clés du dictionnaire). Afficher l'URL de Wikipedia concernant ce groupe.

Résumé

À retenir

- Les tableaux peuvent contenir aussi des tableaux. Il est commode de les présenter sur plusieurs lignes. Un élément sera alors repéré par `t[i][j]` (i et j représentant la ligne et la colonne).
- Une table de données est un arrangement de lignes et de colonnes. Les données sont souvent situées dans des fichiers csv. On peut les importer de deux manières:

```
import csv


with open(fichier, newline='', encoding='utf8') as f:
    table = [ligne for ligne in csv.reader(f, delimiter=';')]
```

ou

```
import csv


with open(fichier, newline='', encoding='utf8') as f:
    table = [dict(ligne) for ligne in csv.DictReader(f, delimiter=';')]
```

Attention à bien ajuster le délimiteur (au besoin, ouvrir le fichier csv pour vérification).