Recherche dans une table

Lien vers les fichiers de travail

```
import csv


with open('data/rapworld.csv', newline='', encoding='utf8') as f:
    t = [dict(ligne) for ligne in csv.DictReader(f, delimiter=';')]
```

Cohérence d'une table

Les données sont-elles valides?

Dans le cours précédent on a importé les données d'un fichier csv dans un tableau. Cependant, rien ne garantit la validité des lignes. Les informations peuvent être manquantes ou incohérentes.

Pour faire un traitement sur l'âge des artistes par exemple, on s'assurera que ce champ est bien renseigné.

```
def est_valide_age(artiste):
    """
    Renvoie True si l'âge est renseigné.
    """
    if artiste['Birthdate'] != '':
        return True
    return False
```

```
table_conforme_age = [art for  art in t if est_valide_age(art) is True]
len(table_conforme_age)
```

```
277
```

On pourrait vérifier que les date d'anniversaire et de décès (*si présente*) sont bien cohérentes.

```
def est_valide_dc(artiste):
    """ Renvoie True si les dates de décès et d'anniversaire sont cohérentes"""
    if artiste['Deathdate'] != '' and artiste['Birthdate'] != '':
        if int(artiste['Deathdate'][0:4]) > int(artiste['Birthdate'][0:4]):
            return True
    return False
```

```python
table_conforme_dc = [art for  art in t if est_valide_dc(art) is True]
len(table_conforme_dc)
```

```
18
```

La table comporte-t-elle des doublons?

Les tables de données ne doivent généralement pas comporter de doublons. La fonction suivante vérifie la présence de doublons dans une table.

```python
def doublon(t):
    """
    Renvoie un booléen correspond à la présence ou non de doublons dans la table.
    t: tableau de dictionnaires
    """
    for i in range(len(t) - 1):
        for j in range(i + 1, len(t)):
            if t[i] == t[j]:
                return True
    return False
```

```python
doublon(t)
```

```
False
```

> **Note**
>
> Cette fonction n'est pas très efficace, notamment sur des tables volumineuses.

Sélection de lignes ou de colonnes

Comment sélectionner des lignes d'une table?

Les opérations faites sur les tables sont en nombre très limité. Parmi celles-ci, on trouve la **sélection** de lignes qui répondent à certain(s) critère(s). Ces critères sont exprimés avec des booléens.

En python, on exprimera ces critères avec des fonctions `condition_` renvoyant un booléen.

Exemple 1

On souhaite sélectionner les artistes dont le début de carrière se situe après une année donnée.

```python
def verifie_condition_1(p_uplet, date):
    """ Renvoie True si le début de carrière de l'artiste 'art' a eu
    lieu après 'date'
    p_uplet: dictionnaire
    date: entier
    """
    cond = False
    if p_uplet['Years Active Start'] != '' and int(p_uplet['Years Active Start']) >= date:
        cond = True
    return cond

def select_1(t, date):
    """
    Renvoie une table dont les lignes vérifient la 'condition_1'.
    t: tableau de dictionnaires
    date: entier
    """
    return [art for art in t if verifie_condition_1(art, date) is True]
```

```python
# Artiste dont le début de carrière remonte à 2017

t_2017 = select_1(t, 2017)
t_2017
```

```
[{'Name': 'Original Flow Mastaz',
  'Categories': 'group',
  'URL': 'https://www.facebook.com/OriginalFlowMastaz/',
  'Years Active Start': '2017',
  'Birthdate': '',
  'Summary': "Original Flow Mastaz is a Hip Hop band from Neuchâtel formed by Akim, Le R',
Seko and Askaine.",
  'Years Active End': '',
  'Deathdate': '',
  'Clip Example YouTube': 'https://www.youtube.com/embed/iTJu8uDyJ8E',
  'City': 'Neuchâtel',
  'Neighborhood': '',
  'Coordinates': '46.999944,6.917182'},
 {'Name': 'Sinya',
  'Categories': 'rapper',
  'URL': 'https://genius.com/Sinyasound-rafale-2-dz-lyrics',
  'Years Active Start': '2017',
  'Birthdate': '1995-08-05',
  'Summary': 'Yassine Benhadji (born 5th august 1995) is a french rappeur of algerian
descent who grew up in Perpignan.',
  'Years Active End': '',
  'Deathdate': '',
  'Clip Example YouTube': 'https://www.youtube.com/embed/WkQveBSw_gI',
  'City': 'Perpignan',
  'Neighborhood': 'Toulouges',
  'Coordinates': '42.670169,2.831146'}]
```

Exemple 2

On souhaite sélectionner les artistes originaires de Lyon.

```python
def verifie_condition_2(p_uplet, v):
    """ Renvoie True si l'artiste vie dans la ville 'v'
    p_uplet: dictionnaire
    v: chaîne
    """
    cond = False
    if p_uplet['City'] != '' and p_uplet['City'] == v:
        cond = True
    return cond

def select_2(t, v):
    """
    Renvoie une table dont les lignes vérifient la 'condition_2'.
    t: tableau de dictionnaires
    v: chaîne
    """
    return [art for art in t if verifie_condition_2(art, v) is True]
```

```python
# Artistes originaires de Lyon

t_lyon = select_2(t, 'Lyon')
t_lyon
```

```
[{'Name': 'Kacem Wapalek',
  'Categories': 'rapper',
  'URL': 'https://www.chantefrance.com/artist/4568059-kacem-wapalek/biographie',
  'Years Active Start': '2009',
  'Birthdate': '',
  'Summary': 'Kacem Wapalek is a french rapper from Lyon. He is a member of the Amasseurs
de Mots (S.L.A.M.)  crew.',
  'Years Active End': '',
  'Deathdate': '',
  'Clip Example YouTube': 'https://www.youtube.com/embed/D19OwfGaNvE',
  'City': 'Lyon',
  'Neighborhood': '',
  'Coordinates': '45.745237,4.839238'},
 {'Name': 'Jorrdee',
  'Categories': 'producer / dj;rapper',
  'URL': 'https://fr.wikipedia.org/wiki/Jorrdee',
  'Years Active Start': '2011',
  'Birthdate': '',
  'Summary': "Jorrdee, born Jordan Bourgeois is a French rapper from Lyon. He's a original
member of the rap crew 667.",
  'Years Active End': '',
  'Deathdate': '',
  'Clip Example YouTube': 'https://www.youtube.com/embed/zvtHEJ6DsK0',
  'City': 'Lyon',
  'Neighborhood': 'Mermoz',
  'Coordinates': '45.731094,4.885971'},
 {'Name': 'Lucio Bukowski',
  'Categories': 'rapper',
  'URL': 'https://genius.com/artists/Lucio-bukowski',
  'Years Active Start': '2007',
  'Birthdate': '',
  'Summary': "Ludovic Villard (better know has Lucio Bukowski) is a French rapper from
Lyon, member of the crew L'animalerie.",
  'Years Active End': '',
  'Deathdate': '',
  'Clip Example YouTube': 'https://www.youtube.com/embed/zsWiNkt9fIw',
  'City': 'Lyon',
  'Neighborhood': '',
  'Coordinates': '45.769508,4.831418'}]
```


Comment sélectionner des colonnes d'une table?

La sélection de colonnes est une opération appelée couramment **projection**.
D'un point de vue pratique, on boucle sur la table originale et on sauvegarde les champs qui nous intéressent dans un tableau annexe.

```python
def projection(t, col):
    """
    Réalise la projection de 't' sur les champs définis dans 'col' et
    renvoie un nouveau tableau;
    t: tableau de dictionnaire
    col: tableau contenant les colonnes à garder
    """
    # Création du tableau annexe
    t_fin = [{} for _ in range(len(t))]
    for i in range(len(t)):
        for champ in col:
            t_fin[i][champ] = t[i][champ]
    return t_fin
```

```python
t2 = projection(t, ['Name','Categories', 'City'])
for i in range(8):
    print(t2[i])
```

```
{'Name': 'Trae Tha Truth', 'Categories': 'rapper', 'City': 'Houston'}
{'Name': '13 Block', 'Categories': 'group', 'City': 'Sevran'}
{'Name': 'Jay Rock', 'Categories': 'rapper', 'City': 'Watts'}
{'Name': 'Droogz Brigade', 'Categories': 'group', 'City': 'Toulouse'}
{'Name': 'Jeff le Nerf', 'Categories': 'rapper', 'City': 'Grenoble'}
{'Name': 'Bitsu', 'Categories': 'rapper', 'City': 'Toulouse'}
{'Name': 'The Opposites', 'Categories': 'group', 'City': 'Amsterdam'}
{'Name': 'Stormzy', 'Categories': 'rapper', 'City': 'London'}
```

Attention

Une projection peut entrainer la présence de doublons

```python
doublon(projection(t, ['Categories', 'City']))
```

```
True
```